



14. Előadás: Neurális Implicit Reprezentációk

Generatív AI és Inverz Módszerek a Képszintézisben
BME-VIK IIT, 2026





Dr. Vaitkus Márton

Motiváció

Deep Image Prior



- Ötlet: tanítsunk meg egy CNN hálót, zajból reprodukálni *egy fix képet!*
- Tapasztalati tény: ha a tanítást korábban leállítjuk (early stopping) gyakran javul a kép minősége (nagyfrekvenciás zaj, artifactok csökkennek, lyukak kitöltődnek)
- **Deep Image Prior**: a mély neurális háló architektúrája egyfajta rekonstrukciós “prior” kényszerít a rekonstruált jelre!



Motiváció



Deep Image Prior

- Ötlet: tanítsunk meg egy CNN hálót, zajból reprodukálni *egy fix képet!*
- Tapasztalati tény: ha a tanítást korábban leállítjuk (early stopping) gyakran javul a kép minősége (nagyfrekvenciás zaj, artifactok csökkennek, lyukak kitöltődnek)
- **Deep Image Prior**: a mély neurális háló architektúrája egyfajta rekonstrukciós “prior” kényszerít a rekonstruált jelre!



Neurális Reprezentációk

Diszkretizációs módszerek




Neurális Reprezentációk

Diszkretizáció helyett — Neurális reprezentáció?


Neurális Reprezentációk

Diszkretizáció helyett — Neurális reprezentáció?





Neurális Reprezentációk

Diszkretizáció helyett — Neurális reprezentáció?



Neurális Reprezentációk


Diszkretizáció helyett — Neurális reprezentáció?




Neurális Reprezentációk

Függvények reprezentációja neurális hálókkal


- Ezidáig: neurális hálókkal sok dimenziós leképezést közelítettünk (pl. kép $\rightarrow$ címke, kép $\rightarrow$ kép)
- Modern trend: 2D/2D koordináta függvények/jelek reprezentációja neurális hálókkal
- Különböző elnevezések:
 - Neurális mező (Neural field)
 - Implicit neurális reprezentáció (INR)
 - Neurális implicit (függvény)
 - “Koordináta” háló




(b) Image regression
 $(x, y) \rightarrow \text{RGB}$



(c) 3D shape regression
 $(x, y, z) \rightarrow \text{occupancy}$



(d) MRI reconstruction
 $(x, y, z) \rightarrow \text{density}$






(e) Inverse rendering
 $(x, y, z) \rightarrow \text{RGB, density}$

Neurális Reprezentációk

Példák


1D Coordinates



1D Signal
Magnitude





2D Coordinates




2D Pixel
Color



3D
Coordinates




3D Volume
Occupancy



Neurális Reprezentációk

Példák

- Kép
- Hang
- Videó
- 3D adatok (sűrűség, távolság, stb.)
- Radiancia mezők (NeRF)
- Fizikai mennyiségek (hőmérséklet, áramlási sebesség, stb.)
- Differenciálegyenletek megoldása (PINN)




Neurális Reprezentációk

Neural Radiance Field (NeRF)

NeRF: Representing Scenes as
Neural Radiance Fields for View Synthesis

Ben Mildenhall^{1*} Pratul P. Srinivasan^{1*} Matthew Tancik^{1*}
Jonathan T. Barron² Ravi Ramamoorthi³ Ren Ng¹

Cited by 14782




Neurális Reprezentációk

Neural Radiance Field (NeRF)

NeRF: Representing Scenes as
Neural Radiance Fields for View Synthesis

Ben Mildenhall^{1*} Pratul P. Srinivasan^{1*} Matthew Tancik^{1*}
Jonathan T. Barron² Ravi Ramamoorthi³ Ren Ng¹

Cited by 14782



Neurális Reprezentációk

Physics-Informed Neural Networks (PINN)





Journal of Computational Physics
Volume 378, 1 February 2019, Pages 686-707



Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations

M. Raissi ^a, P. Perdikaris ^b, G.E. Karniadakis ^a

Cited by (10950)



Neurális Reprezentációk

Physics-Informed Neural Networks (PINN)





Journal of Computational Physics
Volume 378, 1 February 2019, Pages 686-707



Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations

M. Raissi ^a, P. Perdikaris ^b, G.E. Karniadakis ^a




Cited by (10950)



Neurális Reprezentációk

Előnyök és hátrányok


- Előnyök:
 - Adaptív diszkretizáció
 - Erős tömörítési ráta
 - Differenciálhatóság
 - Egyszerű implementáció
- Hátrányok:
 - Költséges optimalizáció
 - Nehézkes interpretáció és módosíthatóság



Neurális Implicit Felületek

- **Neurális implicit felület:** a 3D felületet egy $F_{\theta}(x, y, z)$ neurális háló (implicit) szintfelületeként definiáljuk
- A neurális háló általában egyszerű architektúrájú (tipikusan MLP)
 - Kritikus implementációs részletek: koordináta beágyazás, aktivációs függvények, inicializáció, stb.
- A hálót tipikusan “túlillesztjük” egy adott 3D modell alapján!
 - Nincs “tanulás” vagy “intelligencia” — a neurális hálót csak függvény reprezentációra használjuk!!
- Pontfelhőre illesztés = θ háló paraméterek optimalizációja (pl. SGD/ADAM) mintapontokban való illeszkedésre:

$$L(\theta) = \sum_i w_{p,i} ||F_{\theta}(\mathbf{p}_i) - f_i|| + w_{n,i} ||\nabla F_{\theta}(\mathbf{p}_i) - \mathbf{n}_i|| \rightarrow \min$$



Neurális Implicit Felületek



Figure 4: Thingi10k models compressed to **59kB**, reducing the dataset from 38.85 GB to 590 MB.

On the Effectiveness of Weight-Encoded Neural Implicit 3D Shapes

Neurális Implicit Felületek

Eikonál regularizáció

Implicit Geometric Regularization for Learning Shapes




Amos Gropp¹ Lior Yariv¹ Niv Haim¹ Matan Atzmon¹ Yaron Lipman¹

- Érvényesítsük az “**eikonál**” (egység-gradiens) tulajdonságot (távolságmező szükséges feltétele):

$$\ell(\theta) = \ell_{\mathcal{X}}(\theta) + \lambda \mathbb{E}_{\mathbf{x}} \left(\|\nabla_{\mathbf{x}} f(\mathbf{x}; \theta)\| - 1 \right)^2$$


$$\ell_{\mathcal{X}}(\theta) = \frac{1}{|I|} \sum_{i \in I} \left(|f(\mathbf{x}_i; \theta)| + \tau \|\nabla_{\mathbf{x}} f(\mathbf{x}_i; \theta) - \mathbf{n}_i\| \right)$$

- PINN speciális esete
- Sík reprodukciós tulajdonság
- Gyakran használatos — de sajnos megvan az ára:
 - A loss-ban a deriváltak számításához két backprop pass (vagy numerikus differenciálás) szükséges!
 - Az egész téren mintavételezni kell!



Neurális Implicit Felületek

Boolean operációk




SDF-ek Boolean-ja $\neq$ Boolean SDF-je!!!

Azonos 0 szintfelületek, de különböző implicit függvények!

$|\nabla f(x)| = 1$ (majdnem mindenhol) teljesül!


$|\nabla f(x)| = 1$: SDF szükséges, de nem elégséges feltétele!



Neurális Implicit Felületek


Neurális CSG, regularizáció

Constructive Solid Geometry on Neural Signed Distance Fields





$$E_{\text{CP}} = \frac{1}{|\mathcal{X}|} \sum_{\mathbf{x} \in \mathcal{X}} f_{\theta}(\mathbf{x} - f_{\theta}(\mathbf{x}) \nabla_{\mathbf{x}} f_{\theta}(\mathbf{x}))^2$$

Closest-point loss



Neurális Implicit Felületek

Peremes felületek




Közös gondolat: gradiens vektormező illesztése — számos variáció...

Neurális Implicit Felületek

Koordináta beágyazás – Motiváció


- Kísérlet: tanítsunk egy $(X, Y) \mapsto (R, G, B)$ **ReLU** MLP-t egy adott kép reprodukciójára (pl. L2 pixel hibát optimalizálva)
- Eredmény: homályos kép (még ha több neuron van, mint ahány pixel)!
- Miért?



Neurális Implicit Felületek

Koordináta beágyazás – Motiváció


- Kísérlet: tanítsunk egy $(X, Y) \mapsto (R, G, B)$ **ReLU** MLP-t egy adott kép reprodukciójára (pl. L2 pixel hibát optimalizálva)
- Eredmény: homályos kép (még ha több neuron van, mint ahány pixel)!
- Miért?



Neurális Implicit Felületek


Koordináta beágyazás – Motiváció

- Megfigyelés: egy betanított ReLU MLP tkp. aluláteresztő szűrést végez a tanító adatpontokon (“Neural Tangent Kernel”)!
 - “Spectral bias”: egy ReLU MLP egy függvény alacsonyfrekvenciás komponenseit tudja legkönnyebben reprodukálni
- Magas dimenziójú adatokra ez kifejezetten előnyös (“implicit regularizáció” egy példája)
- Alacsony dimenziójú adatokra már nem mindig ezt szeretnénk...



On the Spectral Bias of Neural Networks


Nasim Rahaman^{*1,2} Aristide Baratin^{*1} Devansh Arpit¹ Felix Draxler² Min Lin¹ Fred A. Hamprecht²
Yoshua Bengio¹ Aaron Courville¹



Neurális Implicit Felületek

Koordináta beágyazás


- Direkt (x, y, z) bemenettel tanítva egy ReLU MLP csak kisfrekvenciás geometriát képes jól közelíteni...
- Megoldás: **koordináta beágyazás** (coordinate embedding)
 - Ld. transformer koordináta enkódolás!
- *Mindig* használjuk, ha ReLU hálóval közelítünk implicit függvényt!



Fourier Features Let Networks Learn High Frequency Functions in Low Dimensional Domains

NeurIPS 2020 (spotlight)

Matthew Tancik* UC Berkeley
Nithin Raghavan UC Berkeley
Pratul Srinivasan* UC Berkeley
Utkarsh Singhal UC Berkeley
Ben Mildenhall* UC Berkeley
Ravi Ramamoorthi UC San Diego
Sara Fridovich-Keil UC Berkeley
Jonathan T. Barron Google Research
Ren Ng UC Berkeley



$$\gamma(\mathbf{x}) = [\gamma_1(\mathbf{x}), \dots, \gamma_n(\mathbf{x})]$$


$$\gamma_{2i}(\mathbf{x}) = \sin(2^{i-1}\pi x_i)$$

$$\gamma_{(2i+1)}(\mathbf{x}) = \cos(2^{i-1}\pi x_i)$$

Sinusoidal Embeddings
Zhong et al. ICLR 2020
Mildenhall et al., ECCV 2020



$$\gamma(\mathbf{x}) = \exp\left(-\frac{\|t - x\|^2}{2\sigma^2}\right)$$

Gaussian Embeddings
Zheng et al., arXiv 2021





Neurális Implicit Felületek

Koordináta beágyazás



Neurális Implicit Felületek

Koordináta beágyazás



Neurális Implicit Felületek

SIREN

- Koordináta beágyazás: 1db szinusz-függvény réteg
- Sinusoidal Representation Networks (SIREN)** – ReLU aktivációkat cseréljük szinusz-függvényekre!

$$\Phi(\mathbf{x}) = \mathbf{W}_n(\phi_{n-1} \circ \phi_{n-2} \circ \dots \circ \phi_0)(\mathbf{x}) + \mathbf{b}_n, \quad \mathbf{x}_i \mapsto \phi_i(\mathbf{x}_i) = \sin(\mathbf{W}_i \mathbf{x}_i + \mathbf{b}_i)$$




- Sokkal jobban reprodukálja a nagyfrekvenciás részleteket, mint a ReLU!

$$\mathcal{L}_{\text{sdf}} = \int_{\Omega} \left\| |\nabla_{\mathbf{x}} \Phi(\mathbf{x})| - 1 \right\| d\mathbf{x} + \int_{\Omega_0} \left\| \Phi(\mathbf{x}) \right\| + \left(1 - \langle \nabla_{\mathbf{x}} \Phi(\mathbf{x}), \mathbf{n}(\mathbf{x}) \rangle \right) d\mathbf{x} + \int_{\Omega \setminus \Omega_0} \psi(\Phi(\mathbf{x})) d\mathbf{x}$$

$$\psi(\mathbf{x}) = \exp(-\alpha \cdot |\Phi(\mathbf{x})|), \alpha \gg 1$$

(Felülettől távoli $\Phi(\mathbf{x}) = 0$ értékek büntetése)

- Speciális inicializációt igényel
- Jó default neurális implicit reprezentációra



Neurális Implicit Felületek

SIREN

- Koordináta beágyazás: 1db szinusz-függvény réteg
- Sinusoidal Representation Networks (SIREN)** – ReLU aktivációkat cseréljük szinusz-függvényekre!

$$\Phi(\mathbf{x}) = \mathbf{W}_n (\phi_{n-1} \circ \phi_{n-2} \circ \dots \circ \phi_0)(\mathbf{x}) + \mathbf{b}_n, \quad \mathbf{x}_i \mapsto \phi_i(\mathbf{x}_i) = \sin(\mathbf{W}_i \mathbf{x}_i + \mathbf{b}_i)$$




- Sokkal jobban reprodukálja a nagyfrekvenciás részleteket, mint a ReLU!

$$\mathcal{L}_{\text{sdf}} = \int_{\Omega} \left\| |\nabla_{\mathbf{x}} \Phi(\mathbf{x})| - 1 \right\| d\mathbf{x} + \int_{\Omega_0} \left\| \Phi(\mathbf{x}) \right\| + \left(1 - \langle \nabla_{\mathbf{x}} \Phi(\mathbf{x}), \mathbf{n}(\mathbf{x}) \rangle \right) d\mathbf{x} + \int_{\Omega \setminus \Omega_0} \psi(\Phi(\mathbf{x})) d\mathbf{x}$$

$$\psi(\mathbf{x}) = \exp(-\alpha \cdot |\Phi(\mathbf{x})|), \alpha \gg 1$$


(Felülettől távoli $\Phi(\mathbf{x}) = 0$ értékek büntetése)

- Speciális inicializációt igényel
- Jó default neurális implicit reprezentációra



Neurális Implicit Felületek


SIREN



Egy SIREN háló minden deriváltja maga is SIREN háló!!

Neurális Implicit Felületek

Hibrid reprezentációk



Neurális háló, mint “interpolációs kernel”


Neurális Implicit Felületek

Hibrid reprezentációk


- Ezidáig: minden információt a neurális háló paramétereiben tároltunk
- **Hibrid / struktúrált reprezentáció:** kombináljunk egy térbeli adatstruktúrát egy neurális hálóval
- Tipikusan: az adatstruktúrában látens vektorokat tárolunk — a(z esetleg interpolált) látens kódot egy neurális háló dekódolja pl. távolság értéké
- A neurális háló ezáltal kisebb/egyszerűbb lehet — az információ “megoszlik” a látens kódok és a háló között!
- Számos variáció lehetséges...

Convolutional Occupancy Networks


Songyou Peng^{1,2} Michael Niemeyer^{2,3} Lars Mescheder^{2,4*}
Marc Pollefeys^{1,5} Andreas Geiger^{2,3}



(c) Convolutional Single-Plane Decoder




(d) Convolutional Multi-Plane Decoder




(e) Convolutional Volume Decoder

Neurális Implicit Felületek


Hibrid reprezentációk — Példák



Látens rács





Tri-plane



Látens halmaz (attention)

Neurális Implicit Felületek

Hibrid reprezentációk — Neurális Level-of-Detail



DeepSDF [39]


FFN [47]

SIREN [45]

Neural Implicits [9]

Ours / LOD 5

Reference



Neurális Implicit Felületek

Hibrid reprezentációk — Instant NGP

Instant Neural Graphics Primitives with a Multiresolution Hash Encoding

THOMAS MÜLLER, NVIDIA, Switzerland


ALEX EVANS, NVIDIA, United Kingdom

CHRISTOPH SCHIED, NVIDIA, USA


ALEXANDER KELLER, NVIDIA, Germany

<https://nvlabs.github.io/instant-ngp>

SIGGRAPH Best Paper
TIME's Best Inventions of 2022



Egymásba ágyazott térbeli hash táblák + kicsi MLP



Optimalizált GPU implementáció — *nagyságrendekkel* gyorsabb tanítás & kiértékelés!

Neurális Implicit Felületek

Hibrid reprezentációk — Instant NGP

Instant Neural Graphics Primitives with a Multiresolution Hash Encoding

THOMAS MÜLLER, NVIDIA, Switzerland


ALEX EVANS, NVIDIA, United Kingdom

CHRISTOPH SCHIED, NVIDIA, USA


ALEXANDER KELLER, NVIDIA, Germany

<https://nvlabs.github.io/instant-ngp>

SIGGRAPH Best Paper
TIME's Best Inventions of 2022



Egymásba ágyazott térbeli hash táblák + kicsi MLP





Optimalizált GPU implementáció — *nagyságrendekkel* gyorsabb tanítás & kiértékelés!

Neurális Implicit Felületek

Hibrid reprezentációk — Neural VDB*


NeuralVDB: High-resolution Sparse Volume Representation using Hierarchical Neural Networks

DOYUB KIM, MINJAE LEE, and KEN MUSETH, NVIDIA, Santa Clara, USA



Neurális Implicit Felületek

Hibrid reprezentációk — fVDB*



*f*VDB: A Deep-Learning Framework for Sparse, Large-Scale, and High-Performance Spatial Intelligence



FRANCIS WILLIAMS, NVIDIA Research, USA
JIAHUI HUANG, NVIDIA Research, USA
JONATHAN SWARTZ, NVIDIA Research, New Zealand
GERGELY KLÁR, NVIDIA Research, New Zealand
VIJAY THAKKAR, NVIDIA Research, USA
MATTHEW CONG, NVIDIA Research, USA
XUANCHI REN, NVIDIA Research, Canada
RUILONG LI, NVIDIA Research, USA
CLEMENT FUJI-TSANG, NVIDIA Research, Canada
SANJA FIDLER, NVIDIA Research, Canada
EFTYCHIOS SIFAKIS, University of Wisconsin-Madison, USA and NVIDIA Research, USA
KEN MUSETH, NVIDIA Research, USA

Hatékony konvolúció VDB adatstruktúrával — km méretű neurális SDF!

Neurális Implicit Felületek

Hibrid reprezentációk – ReLU mezők

- Meglepő megfigyelés: közönséges trilineáris interpoláció + ReLU nemlinearitás már versenyképes lehet egy sokrétegű MLP-vel!




ReLU Fields: The Little Non-linearity That Could

ANIMESH KARNEWAR, University College London, UK

TOBIAS RITSCHER, University College London, UK


OLIVER WANG, Adobe Research, USA

NILOY J. MITRA, Adobe Research, USA and University College London, UK



Neurális Implicit Felületek

Hibrid reprezentációk — Faktor Mezők



Egységes elméleti keretrendszer a különböző hibrid neurális reprezentációkhoz

<https://apchenstu.github.io/FactorFields/>

Neurális Implicit Felületek


Hibrid reprezentációk — Irreguláris diszkretizáció*

3DILG: Irregular Latent Grids for 3D Generative Modeling

Biao Zhang
KAUST
biao.zhang@kaust.edu.sa


Matthias Nießner
Technical University of Munich
niessner@tum.de

Peter Wonka
KAUST
pwonka@gmail.com



PIN-SLAM: LiDAR SLAM Using a Point-Based Implicit Neural Representation for Achieving Global Map Consistency



Yue Pan, Xingguang Zhong, Louis Wiesmann, Thorbjörn Posewsky, Jens Behley, and Cyrill Stachniss



3D pontfelhő + látens vektorok + interpoláció

Neurális Implicit Felületek



Hibrid reprezentációk — Irreguláris diszkretizáció*



<https://oppo-us-research.github.io/NeuRBF-website/>
(Gaussian Splatting-hez hasonló)

Neurális Implicit Felületek

Hibrid reprezentációk — Irreguláris diszkretizáció*




<https://oppo-us-research.github.io/NeuRBF-website/>
(Gaussian Splatting-hez hasonló)

Neurális Implicit Felületek


Hibrid reprezentációk — Attention

3DShape2VecSet: A 3D Shape Representation for Neural Fields and Generative Diffusion Models


BIAO ZHANG, KAUST, Saudi Arabia
JIAPENG TANG, TU Munich, Germany
MATTHIAS NIESSNER, TU Munich, Germany
PETER WONKA, KAUST, Saudi Arabia




(b) Global Latent



(d) Irregular Latent Grid



(e) Latent Set (Ours)




Látens vektorok rendezetlen halmazából figyelemmechanizmussal dekódolunk pl. SDF-et

$$\hat{O}_{\text{RBF}}(\mathbf{x}) = \sum_{i=1}^M \lambda_i \cdot \phi(\mathbf{x}, \mathbf{x}_i) \quad \longleftrightarrow \quad \hat{\mathcal{F}}(\mathbf{x}) = \sum_{i=1}^M \mathbf{v}(\mathbf{f}_i) \cdot \frac{1}{Z(\mathbf{x}, \{\mathbf{f}_i\}_{i=1}^M)} e^{\mathbf{q}(\mathbf{x})^T \mathbf{k}(\mathbf{f}_i) / \sqrt{d}}$$

Attention $\approx$ Gauss simítás tanult látens térben!

Elterjedten használt 3D generatív modellekben!




Neurális Implicit Felületek

Hibrid reprezentációk — Attention


3DShape2VecSet: A 3D Shape Representation for Neural Fields and Generative Diffusion Models

BIAO ZHANG, KAUST, Saudi Arabia
JIAPENG TANG, TU Munich, Germany
MATTHIAS NIESSNER, TU Munich, Germany
PETER WONKA, KAUST, Saudi Arabia




3D Generatív Modellelés

DeepSDF, Occupancy Networks



DeepSDF (2019)



Occupancy Networks (2019)

Úttörő jellegű munkák — generatív alkalmazások által motiválva

3D Generatív Modellezés

Kondicionálási módszerek

Attention Beats Concatenation for Conditioning Neural Fields

Daniel Rebain

*University of British Columbia
Google Research*

Mark J. Matthews

Google Research

Kwang Moo Yi

University of British Columbia

Gopal Sharma




University of British Columbia

Dmitry Lagun

Google Research


Andrea Tagliasacchi

*Google Research
Simon Fraser University*




3D Generatív Modellelés

3DShape2VecSet




3DShape2VecSet: A 3D Shape Representation for Neural Fields and Generative Diffusion Models

BIAO ZHANG, KAUST, Saudi Arabia
 JIAPENG TANG, TU Munich, Germany
 MATTHIAS NIESSNER, TU Munich, Germany
 PETER WONKA, KAUST, Saudi Arabia



CLAY

LONGWEN ZHANG*, ShanghaiTech University and Deemos Technology Co., Ltd., China
 ZIYU WANG*, ShanghaiTech University and Deemos Technology Co., Ltd., China
 QIXUAN ZHANG†, ShanghaiTech University and Deemos Technology Co., Ltd., China
 QIWEI QIU, ShanghaiTech University and Deemos Technology Co., Ltd., China
 ANQI PANG, ShanghaiTech University, China
 HAORAN JIANG, ShanghaiTech University and Deemos Technology Co., Ltd., China
 WEI YANG, Huazhong University of Science and Technology, China
 LAN XU‡, ShanghaiTech University, China
 JINGYI YU‡, ShanghaiTech University, China



3D Generatív Modellezés

CLAY

CLAY: A Controllable Large-scale Generative Model for Creating High-quality 3D Assets

LONGWEN ZHANG*, ShanghaiTech University and Deemos Technology Co., Ltd., China

ZIYU WANG*, ShanghaiTech University and Deemos Technology Co., Ltd., China

QIXUAN ZHANG^{*}, ShanghaiTech University and Deemos Technology Co., Ltd., China

QIWEI QIU, ShanghaiTech University and Deemos Technology Co., Ltd., China

ANQI PANG, ShanghaiTech University, China


HAORAN JIANG, ShanghaiTech University and Deemos Technology Co., Ltd., China

WEI YANG, Huazhong University of Science and Technology, China


LAN XU[‡], ShanghaiTech University, China

JINGYI YU[‡], ShanghaiTech University, China


VAE Geometry Encoder



VAE Geometry Decoder






Latent Diffusion Model



3D Generatív Modellelés

Hunyuan3D



3D Generatív Modellelés

Struktúrált látens generálás (TRELLIS)



<https://microsoft.github.io/TRELLIS/>


3D Assets Encoding & Decoding

Structured Latent Representation Learning




3D Assets Generation



Structure Generation



Structured Latents Generation



Latents Decoding



3D Generatív Modellelés

Struktúrált látens generálás (TRELLIS)



<https://microsoft.github.io/TRELLIS/>


3D Assets Encoding & Decoding

Structured Latent Representation Learning




3D Assets Generation



Structure Generation



Structured Latents Generation



Latents Decoding



Következő előadás:

Inverz grafika alapjai

() - 1



Geometry, materials, emitters, ...

$$\xrightarrow{\text{Rendering}} \\ \mathbf{y} = f(\mathbf{x})$$

$$\xleftarrow{\text{Inverse rendering}} \\ \mathbf{x} = f^{-1}(\mathbf{y})?$$

